

The background of the slide features a dense arrangement of bright green leaves with serrated edges, filling the upper portion. The lower portion shows a close-up of water with gentle ripples, creating a textured, blue-green effect. A semi-transparent white rounded rectangle is centered over the image, containing the title text.

Modelo Lineal General



III. MODELO DE REGRESIÓN LINEAL GENERAL

Objetivos

1. Expresar un modelo de regresión lineal de manera desarrollada.
2. Conocer las hipótesis en las que se basa el modelo de regresión lineal general.
3. Realizar un análisis de regresión con dos o más variables económicas de manera satisfactoria.
4. Utilizar el álgebra matricial para expresar el modelo y para recoger expresiones relativas tanto el estimador de mínimos cuadrados ordinarios como a las propiedades de dicho estimador.
5. Conocer las propiedades del estimador de MCO
6. Comprender la lógica de la estimación de los parámetros por máxima verosimilitud.
7. Conocer e interpretar las medidas de bondad del ajuste.
8. Realizar inferencia sobre los parámetros individuales, en concreto, contrastes de hipótesis e intervalos de confianza en el contexto de un modelo de regresión lineal de más de dos variables.



III. MODELO DE REGRESIÓN LINEAL GENERAL

Objetivos (cont.)

9. Realizar contrastes de restricciones lineales sobre los parámetros, con especial incidencia en el contraste conjunto de significación de parámetros.
10. Comprender la lógica del estimador de mínimos cuadrados restringidos.
11. Comprender las propiedades del estimador de mínimos cuadrados restringidos.
12. Conocer las restricciones especiales y sus implicaciones principales.
13. Construir intervalos de confianza para la predicción del valor medio y del valor puntual.
14. Evaluar y validar los resultados obtenidos en un modelo de regresión
15. Interpretar económicamente los resultados de un modelo de regresión de más de dos variables
16. Practicar la estimación, realización de contrastes e interpretación de modelos econométricos de más de dos variables mediante el paquete econométrico EVIEWS.



III. MODELO DE REGRESIÓN LINEAL GENERAL

Índice

1. Especificación e hipótesis del modelo.
2. Estimación de los parámetros por el método de Mínimos Cuadrados Ordinarios.
3. Propiedades del estimador de MCO.
4. Estimación de σ^2 .
5. Estimación de los parámetros por máxima verosimilitud.
6. Bondad del ajuste: Coeficiente de determinación y coeficiente de determinación ajustado,
7. Inferencia: intervalos de confianza y contrastes estadísticos para los parámetros individuales.
8. Contraste del modelo conjunto. Contrastes de restricciones lineales
9. Combinación de información muestral y no muestral: estimación restringida
10. Restricciones especiales: no lineales, de desigualdad y estocásticas
11. Predicción en el modelo lineal general
12. Evaluación y validación de modelos

III. MODELO DE REGRESIÓN LINEAL GENERAL

1. Especificación e hipótesis del modelo

1.1. Especificación

Definición: Se llama Modelo de Regresión Lineal General al modelo probabilístico $y = \beta_1 + \beta_2 x_2 + \dots + \beta_k x_k + e$

✚ Para la estimación de la **estructura** -desconocida- del modelo se dispone de un conjunto de n observaciones $(y_i, x_{2i}, \dots, x_{ki})$, $i = 1, \dots, n$, de modo que para cada una de ellas, es decir para $i = 1, \dots, n$, se tiene

$$y_i = \beta_1 + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + e_i,$$

o bien, haciendo $x_{1i} = 1 \quad \forall i$,

$$y_i = \sum_{j=1}^k \beta_j x_{ji} + e_i$$

III. MODELO DE REGRESIÓN LINEAL GENERAL

1. Especificación e hipótesis del modelo (cont.)

El conjunto de igualdades puede expresarse matricialmente:

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{21} & \cdots & x_{k1} \\ \vdots & \vdots & \cdots & \vdots \\ 1 & x_{2n} & \cdots & x_{kn} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} e_1 \\ \vdots \\ e_n \end{bmatrix} \quad \text{o} \quad y = X\beta + e$$

- $y = (y_1, \dots, y_n)'$ es el vector columna de las observaciones de la variable endógena.
- $X = (x_{ij})$ $i = 1, \dots, n; j = 1, \dots, k$ es la matriz, de orden (n, k) , de las observaciones de las variables exógenas, considerando $x_{1i} = 1 \quad \forall i$.
- La fila i -ésima de la matriz X , $x_i = (1, x_{2i}, \dots, x_{ki})$ contiene los valores de la observación i -ésima para las k variables explicativas del modelo.
- La columna j -ésima de X , $(x_{j1}, \dots, x_{jn})'$ contiene los n valores observados para la variable x_j .
- $\beta = (\beta_1, \beta_2, \dots, \beta_k)'$ es el vector que contiene los parámetros del modelo
- $e = (e_1, \dots, e_n)'$ es el vector de los errores o perturbaciones aleatorias.

III. MODELO DE REGRESIÓN LINEAL GENERAL

1.2. Hipótesis básicas del modelo

H1: El modelo está **bien especificado**, es decir, la **especificación estocástica** de la función de regresión poblacional es $y_i = \beta_1 + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + e_i$ o, matricialmente, $y = X\beta + e$

H1.1: Se incluyen en el modelo todas las variables relevantes.

H1.2: El término de error, e_i , actúa aditivamente.

H1.3: La relación es lineal en los parámetros.

H1.4: Los parámetros estructurales (coeficientes de regresión poblacionales) son constantes, no variando ni en el horizonte de observación ni en el de predicción.

H2: La matriz X es una **matriz no estocástica** y toma valores fijos en muestras repetidas.

También ha de cumplirse que $\text{rango}(X) = k < n$ (**hipótesis de rango pleno**):

- más observaciones que parámetros a estimar,
- no multicolinealidad.

H3: $\forall i \ E[e_i/X] = 0$, (**hipótesis de esperanza nula de los errores**).

Matricialmente esta condición se expresa como:

$$E[e/X] = \begin{bmatrix} E(e_1/X) \\ \vdots \\ E(e_n/X) \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix} = 0_n$$

III. MODELO DE REGRESIÓN LINEAL GENERAL

1.2. Hipótesis básicas del modelo (Cont.)

H4: $\forall i \text{ } Var[e_i / X] = \sigma^2 > 0$, hipótesis de **homoscedasticidad** (igual dispersión) o igualdad de las varianzas condicionadas de los errores.

H5: $\forall i \neq j \text{ } Cov[e_i, e_j / X] = 0$, hipótesis de ausencia de correlación en los errores. (**No autocorrelación**)

H6: Cada perturbación e_i sigue una distribución normal y, por tanto, el vector $e = (e_1, \dots, e_n)'$ sigue una distribución normal multivariante. (Hipótesis de **normalidad de los errores**).

Nota: representaciones adicionales

Las hipótesis H4 y H5 pueden ser agrupadas expresando la matriz de covarianzas del vector de las perturbaciones, e , como

$$Cov(e) = E[(e - E(e))(e - E(e))'] = E(ee') = (Cov(e_i, e_j)) = \sigma^2 I_n$$

$$Cov(e) = (Cov(e_i, e_j)) = \begin{bmatrix} Var(e_1) & Cov(e_1, e_2) & \cdots & Cov(e_1, e_n) \\ Cov(e_1, e_2) & Var(e_2) & \cdots & Cov(e_2, e_n) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(e_1, e_n) & \cdots & \cdots & Var(e_n) \end{bmatrix} = \begin{bmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \sigma^2 \end{bmatrix} = \sigma^2 I_n$$

III. MODELO DE REGRESIÓN LINEAL GENERAL

1.2. Hipótesis básicas del modelo (Cont.)

Nota: representaciones adicionales (cont.)

- Las perturbaciones que cumplen esta hipótesis (homoscedasticidad y no autocorrelación) son conocidas como **perturbaciones esféricas**.
- La hipótesis 3, 4, 5 y 6 pueden resumirse en: $e / X \approx N(0_n, \sigma^2 I_n)$
- La hipótesis de normalidad no es necesaria para obtener algunos de los resultados más importantes de la regresión múltiple. Su necesidad estriba, básicamente, en la posibilidad de obtener distribuciones exactas de los estadísticos utilizados.
- De acuerdo con las hipótesis establecidas, es inmediato deducir que la **función de regresión poblacional**, desconocida, es una **función lineal** (hiperplano) dada por

$$E(y_i / x_{2i}, \dots, x_{ki}) = \beta_1 + \beta_2 x_{2i} + \dots + \beta_k x_{ki}$$

o, matricialmente, $E(y / X) = E(X\beta + e) = X\beta + E(e / X) = X\beta$.

- La matriz de covarianzas de y viene dada por:

$$\text{Cov}(y / X) = \text{Cov}(X\beta + e) = \text{Cov}(e) = \sigma^2 I_n$$

- Por consiguiente, con los resultados anteriores se tiene que $y \approx N(X\beta; \sigma^2 I_n)$.

III. MODELO DE REGRESIÓN LINEAL GENERAL

2. Estimación de los parámetros por mínimos cuadrados ordinarios (MCO)

✚ *Estimación de la función de regresión poblacional: la ecuación del hiperplano más próximo a la nube o conjunto de puntos muestrales.*

✚ MCO → el plano más próximo al conjunto de puntos muestrales es aquel para el cual se hace mínima la cantidad:

$$S(\hat{\beta}) = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

✚ La *función minimando* también se puede expresar *matricialmente* en la forma:

$$S(\hat{\beta}) = \sum \hat{e}_i^2 = (\hat{e}_1 \quad \cdots \quad \hat{e}_n) \begin{pmatrix} \hat{e}_1 \\ \vdots \\ \hat{e}_n \end{pmatrix} = \hat{e}' \hat{e} = (y - X\hat{\beta})'(y - X\hat{\beta}) = y'y - 2\hat{\beta}'X'y + \hat{\beta}'X'X\hat{\beta}$$

✚ *Para obtener los valores de los parámetros que minimizan la función derivamos respecto de $\hat{\beta}$ e igualamos a 0 (condición de primer orden) :*

$$\frac{\partial S(\hat{\beta})}{\partial \hat{\beta}} = -2X'y + 2X'X\hat{\beta} = 0 \Leftrightarrow X'y = X'X\hat{\beta}$$

$X'X$ es matriz cuadrada de orden k y rango $k \rightarrow \exists (X'X)^{-1}$,

Premultiplicando las ecuaciones normales por $(X'X)^{-1}$, se obtienen las **estimaciones MCO** de β

$$\hat{\beta} = (X'X)^{-1} X'y$$

III. MODELO DE REGRESIÓN LINEAL GENERAL

3. Propiedades del estimador de MCO

✚ Cuando la expresión $b = (X'X)^{-1}X'y$ se considera función de los valores de la variable y para distintas muestras hablaremos del *estimador* MCO:

$$\hat{\beta} = (X'X)^{-1}X'y$$

➔ al tratarse de una v. a.

¿qué propiedades caracterizan su distribución?

1. Es función *lineal* de y .

En efecto, puesto que $\hat{\beta} = (X'X)^{-1}X'y = Ty$

donde $T = (X'X)^{-1}X'$ es una matriz de valores fijos.

2. Es un *estimador insesgado*. $E(\hat{\beta} / X) = E(\hat{\beta}) = \beta$

$$\begin{aligned}\hat{\beta} &= (X'X)^{-1}X'y = (X'X)^{-1}X'(X\beta + e) = \\ &= (X'X)^{-1}(X'X)\beta + (X'X)^{-1}X'e = \beta + (X'X)^{-1}X'e\end{aligned}$$

y, como por hipótesis $E(e) = 0$, se tiene que

$$E(\hat{\beta}) = \beta + (X'X)^{-1}X'E(e) = \beta$$



III. MODELO DE REGRESIÓN LINEAL GENERAL

3. Propiedades del estimador de MCO (Cont.)

3. Matriz de covarianzas:
$$Cov(\hat{\beta}) = (Cov(\beta_i, \beta_j)) = \sigma^2 (X'X)^{-1}$$

$$\begin{aligned} Cov(\hat{\beta}) &= E((\hat{\beta} - \beta)(\hat{\beta} - \beta)') = E((X'X)^{-1}X'ee'X(X'X)^{-1}) = \\ &= (X'X)^{-1}X'E(ee')X(X'X)^{-1} = (X'X)^{-1}X'\sigma^2IX(X'X)^{-1} = \\ &= \sigma^2(X'X)^{-1}X'X(X'X)^{-1} = \sigma^2(X'X)^{-1} \end{aligned}$$

En forma desarrollada:

$$Cov(\hat{\beta}) = (Cov(\hat{\beta}_i, \hat{\beta}_j)) = \begin{pmatrix} Var(\hat{\beta}_1) & Cov(\hat{\beta}_1, \hat{\beta}_2) & \dots & Cov(\hat{\beta}_1, \hat{\beta}_k) \\ Cov(\hat{\beta}_1, \hat{\beta}_2) & Var(\hat{\beta}_2) & \dots & Cov(\hat{\beta}_2, \hat{\beta}_k) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(\hat{\beta}_1, \hat{\beta}_k) & \dots & \dots & Var(\hat{\beta}_k) \end{pmatrix} = \sigma^2 (X'X)^{-1}$$

Para los parámetros individuales, siendo $(a_{ij}) = (X'X)^{-1}$, se tiene que

$$Var(\hat{\beta}_i) = \sigma^2 a_{ii}$$

$$Cov(\hat{\beta}_i, \hat{\beta}_j) = \sigma^2 a_{ij}$$



III. MODELO DE REGRESIÓN LINEAL GENERAL

3. Propiedades del estimador de *MCO* (Cont.)

4. El vector de residuos \hat{e} , es ortogonal a la matriz de variables explicativas, X :

$$X' \hat{e} = 0$$

5. La media de los residuos es 0: $\bar{\hat{e}}_i = 0$ y $\sum_i \hat{e}_i = 0$

6. **Teorema de Gauss-Markov**: El estimador MCO, es óptimo dentro de la clase de los estimadores lineales e insesgados de β

(MELI: Mejor Estimador Lineal Insesgado)

7. Consistencia: $p \lim \left[\hat{\beta}_j \right] = \beta_j$

8. Eficiencia, eficiencia asintótica y normalidad.

4. Estimación de σ^2

- Como estimador de la varianza de las distribuciones condicionadas de los errores se toma la *varianza residual*

$$\hat{\sigma}^2 = \frac{\sum \hat{e}_i^2}{n - k} = \frac{\hat{e}' \hat{e}}{n - k}$$

- La *varianza residual* es un estimador insesgado de σ^2

$$E(\hat{\sigma}^2) = \sigma^2$$



III. MODELO DE REGRESIÓN LINEAL GENERAL

5. Estimación de los parámetros por máxima verosimilitud

$$y = X\beta + e, \quad e = (e_1, \dots, e_n)', \quad e / X \approx N(0_n, \sigma^2 I_n)$$



$$y \approx N(X\beta, \sigma^2 I_n)$$

Se dispone de una muestra aleatoria de n observaciones

$$(y_i, x_{2i}, \dots, x_{ki})_{i=1, \dots, n}$$



Función de densidad del vector de observaciones de la variable endógena, $y = (y_1, \dots, y_n)'$, vendrá dada por:



$$\begin{aligned} f(y; \beta, \sigma^2) &= f(y_1, \dots, y_n; \beta_1, \dots, \beta_k; \sigma^2) = \prod_{i=1}^n f(y_i, \beta, \sigma^2) = \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(y_i - \sum \beta_j x_{ji})^2\right\} = \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum (y_i - \sum \beta_j x_{ji})^2\right\} = \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum e_i^2\right\} = \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta)\right\} \end{aligned}$$





III. MODELO DE REGRESIÓN LINEAL GENERAL

5. Estimación de los parámetros por máxima verosimilitud (Cont.)

✚ Función de verosimilitud de la muestra:

$$L(\beta, \sigma^2; y) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta)\right)$$

✚ Tomando logaritmos

$$l(\beta, \sigma^2, y) = \log L(\beta, \sigma^2, y) = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta)$$

¿Valores de β y σ^2 que hacen máxima la función l ?

Se deriva respecto de cada conjunto de parámetros:

$$\frac{\partial l}{\partial \beta} = -\frac{1}{2\sigma^2} (-2X'y + 2X'X\beta) = 0 \quad \Leftrightarrow \quad X'X\beta = X'y$$

$$\frac{\partial l}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{\sigma^4} (y - X\beta)'(y - X\beta) = 0 \quad \Leftrightarrow \quad \frac{n}{2\sigma^2} = \frac{1}{\sigma^4} (y - X\beta)'(y - X\beta) = 0$$

$X'X\beta = X'y \rightarrow$ sistema de **ecuaciones normales**

$$\hat{\beta}_{MV} = \hat{\beta} = (X'X)^{-1} X'y$$

El estimador MCO de β goza de las propiedades del estimador de MV:

consistencia, insesgadez y eficiencia asintóticas.



$$\frac{n}{2\sigma^2} = \frac{1}{\sigma^4} \hat{e}'\hat{e} \Rightarrow \hat{\sigma}_{MV}^2 = \frac{\hat{e}'\hat{e}}{n}$$

Estimador **sesgado**, aunque **consistente**.

$$E[\hat{\sigma}_{MV}^2] = E\left[\frac{\hat{e}'\hat{e}}{n}\right] = \frac{n-k}{n} E\left[\frac{\hat{e}'\hat{e}}{n-k}\right] = \frac{n-k}{n} \sigma^2$$

III. MODELO DE REGRESIÓN LINEAL GENERAL

6. Bondad del ajuste

$$SRC = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

No es una medida homogénea
se ve afectada por la escala de medida



Otras medidas

6.1. Descomposición de la variación de la variable dependiente

Sumas de cuadrados: Variación total de la variable dependiente alrededor de su media

$$\boxed{\Sigma(y_i - \bar{y})^2} = \boxed{\Sigma(\hat{y}_i - \bar{y})^2} + \boxed{\Sigma(y_i - \hat{y}_i)^2} \quad \text{o} \quad \Sigma(y_i - \bar{y})^2 = \Sigma(\hat{y}_i - \bar{y})^2 + \Sigma\hat{e}_i^2$$

$\underbrace{\hspace{1.5cm}}_{STC} = \underbrace{\hspace{1.5cm}}_{SEC} + \underbrace{\hspace{1.5cm}}_{SRC}$
Total = Explicada + Residual

6.2. Coeficiente de determinación: R^2

% de la variación total de la variable dependiente explicada por el modelo:

$$\boxed{R^2 = \frac{SEC}{STC} = \frac{\Sigma(\hat{y}_i - \bar{y})^2}{\Sigma(y_i - \bar{y})^2} = 1 - \frac{SRC}{STC} = 1 - \frac{\Sigma(y_i - \hat{y}_i)^2}{\Sigma(y_i - \bar{y})^2}}$$

$$\boxed{R^2} = \frac{\hat{\beta}' X' Y - n\bar{y}^2}{y' y - n\bar{y}^2} = 1 - \frac{y' y - \hat{\beta}' X' y}{y' y - n\bar{y}^2} = 1 - \frac{\hat{e}' \hat{e}}{y' y - n\bar{y}^2} = \boxed{1 - \frac{(n-k)\hat{\sigma}^2}{ns_y^2}}$$

III. MODELO DE REGRESIÓN LINEAL GENERAL

6. Bondad del ajuste. Coeficiente de determinación: R^2

Propiedades:

1. $0 \leq R^2 \leq 1$, (cuando \exists término independiente)
2. $R^2 = (r_{y,\hat{y}})^2$
3. $R^2 = 1$ (ajuste perfecto) \longrightarrow (STC = SEC o SRC = 0)
4. $R^2 = 0$, (STC = SRC) \longrightarrow $y_i = \bar{y} + e_i$

6.3. Coeficiente de determinación ajustado

Problemas que presenta R^2 :

- ✚ R^2 se incrementa (ó no disminuye) cuando aumenta el número de variables
- ✚ No son comparables mediante el R^2 :
 - Regresiones con la misma variable dependiente, pero distinto n°. de variables
 - Regresiones con diferentes variables dependientes
- ✚ Se introduce una nueva medida, *el coeficiente de determinación ajustado* eliminando el efecto que el n° de variables (con la pérdida de grados de libertad) introduce en R^2 .

$$\overline{R^2} = 1 - \frac{SRC / (n - k)}{STC / (n - 1)} = 1 - \frac{\hat{\sigma}^2}{s_y^2} = 1 - (1 - R^2) \frac{n - 1}{n - k}$$

Puede disminuir cuando se incorporan nuevas variables si no compensa la pérdida de grados de libertad (el aumento de su valor al incluir una nueva variable dependerá de su contribución al modelo).

III. MODELO DE REGRESIÓN LINEAL GENERAL

7. Inferencia: intervalos de confianza y contrastes de los parámetros individuales

7.1. Distribución de los estimadores de los parámetros individuales

$$\begin{array}{l} \hat{\beta} \approx N(\beta, \sigma^2 (X'X)^{-1}) \\ \text{Cov}(\hat{\beta}, \hat{e}) = 0 \end{array} \Rightarrow \hat{\beta} \text{ y } \hat{e} \text{ son independientes}$$

$$\begin{array}{l} \frac{(\hat{\beta}_i - \beta_i)}{\sigma \sqrt{a_{ii}}} \approx N(0,1) \\ \frac{(n-k)\hat{\sigma}^2}{\sigma^2} = \frac{\sum \hat{e}_i^2}{\sigma^2} = \frac{e'e}{\sigma^2} \approx \chi_{n-k}^2 \end{array}$$

$$t = \frac{\frac{(\hat{\beta}_i - \beta_i)}{\sigma \sqrt{a_{ii}}}}{\sqrt{\frac{(n-k)\hat{\sigma}^2}{\sigma^2 (n-k)}}} = \frac{(\hat{\beta}_i - \beta_i)}{\hat{\sigma} \sqrt{a_{ii}}} = \frac{(\hat{\beta}_i - \beta_i)}{se(\hat{\beta}_i)} \approx t_{n-k}$$

- Intervalos de confianza
- Contrastes estadísticos

III. MODELO DE REGRESIÓN LINEAL GENERAL

7. Inferencia: intervalos de confianza y contrastes de los parámetros individuales

7.2. Intervalos de confianza

Intervalo al $(1-\alpha)\%$ de confianza para β_i :

$$I_{(1-\alpha)\%}(\beta_i) = (\hat{\beta}_i - t_{\alpha/2; n-k} s(\hat{\beta}_i), \hat{\beta}_i + t_{\alpha/2; n-k} s(\hat{\beta}_i)) = \\ = (\hat{\beta}_i - t_{\alpha/2; n-k} \hat{\sigma} \sqrt{a_{ii}}, \hat{\beta}_i + t_{\alpha/2; n-k} \hat{\sigma} \sqrt{a_{ii}})$$

7.3. Contrastes de hipótesis

$$H_0: \{\beta_i = \beta_i^0\} \text{ vs. } H_1: \{\beta_i \neq \beta_i^0\}$$

Estadístico de prueba

$$t = \frac{(\hat{\beta}_i - \beta_i^0)}{s(\hat{\beta}_i)} \xrightarrow{H_0} t_{n-k}$$

Región crítica

$$|t| > t_{\alpha/2, n-k}$$

III. MODELO DE REGRESIÓN LINEAL GENERAL

8. Contraste del modelo conjunto. Contrastes de restricciones lineales

8.1. Resultados estadísticos previos

Sea X un vector aleatorio n -dimensional:

1. $X \approx N(\mu, \Sigma)$ y T matriz fija $\Rightarrow TX \approx N(T\mu, T\Sigma T')$
2. $X \approx N(\mu, \Sigma) \Rightarrow (X - \mu)' \Sigma^{-1} (X - \mu) \approx \chi_n^2$
3. $Z_1 \approx \chi_n^2$ y $Z_2 \approx \chi_m^2$ independientes $\Rightarrow \frac{Z_1/n}{Z_2/m} = \frac{\chi_n^2/n}{\chi_m^2/m} \approx F_{n,m}$

Aplicado a nuestro caso nos lleva a que:

$$Y \approx N(X\beta; \sigma^2 I) \Rightarrow \hat{\beta} = (X'X)^{-1} X'Y \approx N(\beta, \sigma^2 (X'X)^{-1}) \Rightarrow \frac{(\hat{\beta} - \beta)' (X'X) (\hat{\beta} - \beta)}{\sigma^2} \approx \chi_k^2$$
$$\frac{(n-k)\hat{\sigma}^2}{\sigma^2} = \frac{\hat{e}'\hat{e}}{\sigma^2} = \chi_{n-k}^2 \quad \text{y} \quad \hat{\beta} \text{ y } \hat{e} \text{ (independientes)}$$



$$\frac{(\hat{\beta} - \beta)' (X'X) (\hat{\beta} - \beta) / k}{\hat{\sigma}^2} = \frac{(\hat{\beta} - \beta)' (X'X) (\hat{\beta} - \beta) / k}{\hat{e}'\hat{e} / (n-k)} \approx F_{k, n-k}$$

III. MODELO DE REGRESIÓN LINEAL GENERAL

8.2. Contrastes de restricciones lineales sobre β

✚ Sea R una matriz de restricciones lineales sobre β , siendo $\text{rango}(R) = q < k$

Ejemplo: Restricciones $\beta_2 = 0, \beta_3 = \beta_4, \beta_1 + 2\beta_5 + 3\beta_6 = 2, \beta_1 + \beta_4 + \beta_5 + \beta_6 = 0$

Matricialmente
$$\begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & -1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 2 & 3 \\ 1 & 0 & 0 & 1 & 1 & 1 \end{bmatrix} (\beta_1, \beta_2, \beta_3, \beta_4, \beta_5)' = \begin{bmatrix} 0 \\ 0 \\ 2 \\ 0 \end{bmatrix}$$

- 1) del epígrafe anterior, $R\hat{\beta} \approx N(R\beta, \sigma^2 R(X'X)^{-1}R')$ es un vector q -dimensional, con distribución normal.

De 2) y 3) Si $R\beta = r$ se tiene que

$$F = \frac{(R\hat{\beta} - r)' (R(X'X)^{-1}R')^{-1} (R\hat{\beta} - r) / q}{\hat{\sigma}^2} = (R\hat{\beta} - r)' \left(\hat{\text{Cov}}(R\hat{\beta}) \right)^{-1} (R\hat{\beta} - r) / q \approx F_{q, n-k}$$

Luego:

✚ Para el contraste $H_0 : \{R\beta = r\}$ vs. $H_1 : \{R\beta \neq r\}$

✚ La región crítica estará dada por

$$F > F_{\alpha; q; n-k}$$

III. MODELO DE REGRESIÓN LINEAL GENERAL

Contrastes de restricciones lineales. 8.3. Contraste de validez general del modelo

✚ **Hipótesis a contrastar:** $H_0 : \{\beta_2 = 0, \beta_3 = 0, \dots, \beta_k = 0\}$ vs. $H_1 : \{\exists j > 1 / \beta_j \neq 0\}$
equivalente a $H_0 : \{Y_i = \beta_1 + e_i\}$ vs. $H_1 : \{y_i = \beta_1 + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + e_i\}$

✚ **Matriz de restricciones:**

rango de $R = k - 1$

(igual al número de restricciones)

$$R = \begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \dots & \ddots & \vdots \\ 0 & \dots & \dots & 0 & 1 \end{bmatrix} = (0 : I_{k-1})$$

✚ **Estadístico de contraste**

$$F = \frac{(R\hat{\beta})'(R(X'X)^{-1}R')^{-1}(R\hat{\beta})/(k-1)}{\hat{\sigma}^2}$$

✚ **Bajo la hipótesis nula $H_0 : \{R\beta = 0\}$, es:**

$$F = \frac{(R\hat{\beta})'(X'X)(R\hat{\beta})/(k-1)}{\hat{\sigma}^2} = \frac{SEC/(k-1)}{SRC/(n-k)} = \frac{(SEC/STC)/(k-1)}{(SRC/STC)/(n-k)} = \frac{R^2/(k-1)}{(1-R^2)/(n-k)} \approx F_{k-1, n-k}$$

✚ **Por tanto, la región crítica es:**

$$F > F_{\alpha; k-1, n-k}$$



III. MODELO DE REGRESIÓN LINEAL GENERAL

8.3. Contraste de validez general del modelo. Cuadro de Análisis de la Varianza



Para el cálculo del estadístico F se acostumbra a utilizar el siguiente **cuadro de análisis de la varianza** general.

Fuente de variación	Suma de cuadrados	Grados de libertad	Cuadrado Medio	F
Regresión x_2, \dots, x_k	$SEC = \hat{\beta}' X' y - n\bar{y}^2$	$k - 1$	$SEC / (k - 1)$	$\frac{SEC/(k-1)}{SRC/(n-k)} \approx F$
Residual	$SRC = y' y - \hat{\beta} X' y$	$n - k$	$SRC / (n - k) = \hat{\sigma}^2$	
Total	$STC = y' y - n\bar{y}^2$	$n - 1$		

III. MODELO DE REGRESIÓN LINEAL GENERAL

9. Combinación de información muestral y no muestral: estimación restringida

Mínimos Cuadrados Restringidos (MCR)

- ✚ Supongamos que se tiene información *a priori* sobre el modelo: $R\beta = r$
- ✚ Si se incorporan las restricciones al modelo, *reparametrizándolo*, y se lleva cabo la estimación MCO, el método es conocido como **Mínimos Cuadrados Restringidos**
- ✚ Es equivalente a minimizar $S(\beta) = (y - X\beta)'(y - X\beta)$ sujeta a $R\beta = r$
Que es lo mismo que minimizar $L(\beta) = (y - X\beta)'(y - X\beta) - \lambda'(R\beta - r)$
donde $\lambda = (\lambda_1, \dots, \lambda_q)'$ es el vector de multiplicadores de Lagrange
- ✚ La solución está dada por el **Estimador de mínimos cuadrados restringidos**:

$$\hat{\beta}_R = \hat{\beta} + (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}(r - R\hat{\beta})$$

III. MODELO DE REGRESIÓN LINEAL GENERAL

9. Combinación de información muestral y no muestral: estimación restringida (Cont.)

Propiedades del estimador MCR

✚ $\hat{\beta}_R$ insesgado $\longleftrightarrow R\beta = r$

✚ $R\hat{\beta}_R = r$

✚ $Cov(\hat{\beta}_R) \leq Cov(\hat{\beta})$ aún cuando las restricciones sean falsas

Forma habitual de proceder

✚ Si las *restricciones* son *válidas* se debe tomar el estimador MCR:
 $\hat{\beta}_R$ será insesgado y de menor varianza

✚ Si las *restricciones* no son *válidas* se debe tomar el de MCO
El de MCR será sesgado

III. MODELO DE REGRESIÓN LINEAL GENERAL

9. Combinación de información muestral y no muestral: estimación restringida (Cont.)

✚ Se estima el modelo sin restringir, obteniéndose los residuos no restringidos \hat{e} y la suma de los cuadrados de los mismos, $SRC_{NR} = \hat{e}'\hat{e}$.

✚ Se estima el modelo restringido (reparametrizando el modelo original de acuerdo con las restricciones dadas), obteniéndose los residuos \hat{e}_R y la suma de los cuadrados de sus residuos (restringidos): $SRC_R = \hat{e}_R'\hat{e}_R$.

✚ Si las restricciones $R\beta = r$ son válidas, el estadístico

$$F = \frac{(R\hat{\beta} - r)'(R(X'X)^{-1}R')^{-1}(R\hat{\beta} - r)/q}{\hat{\sigma}^2} = \frac{(\hat{e}_R'\hat{e}_R - \hat{e}'\hat{e})/q}{\hat{e}'\hat{e}/(n-k)} = \frac{(SRC_R - SRC_{NR})/q}{SRC_{NR}/(n-k)} \approx F_{q;n-k}$$

Por tanto:

🌍 Si $F > F_{\alpha; q; n-k}$ rechazamos $H_0: \{R\beta = r\}$ tomamos el estimador MCO

🌍 Si $F < F_{\alpha; q; n-k}$ aceptamos $H_0: \{R\beta = r\}$ y se toma el estimador restringido

III. MODELO DE REGRESIÓN LINEAL GENERAL

11. Predicción en el modelo lineal general

✚ Modelo poblacional –desconocido- $y = X\beta + e$,

✚ Modelo ajustado ó estimado por MCO:

función de regresión muestral $\hat{y} = X\hat{\beta}$

✚ El *objetivo de la predicción* puede ser, dados los distintos niveles de las variables explicativas contenidos en el vector x_0 ; $x'_0 = (1, x_{20}, \dots, x_{k0})$

➤ estimar el *valor medio* $E[y / x'_0]$

➤ estimar el *valor individual* y_0

✚ El *estimador* propuesto es el mismo

$$\hat{y}_0 = \hat{\beta}_1 + \hat{\beta}_2 x_{20} + \dots + \hat{\beta}_k x_{k0} = (1, x_{20}, \dots, x_{k0}) \begin{pmatrix} \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_k \end{pmatrix} = x'_0 \hat{\beta}$$

✚ En ambos caso es el mejor predictor lineal insesgado

✚ Las varianzas de los estimadores son distintas

III. MODELO DE REGRESIÓN LINEAL GENERAL

11. Predicción en el modelo lineal general (Cont.)

Para hacer inferencias sobre las predicciones se debe tener en cuenta que

- Las varianzas de los estimadores son distintas, respectivamente:

$$Var \hat{E}[y / x_0] = Var(x_0'(\beta - \hat{\beta})) = \sigma^2(x_0'(X'X)^{-1}x_0)$$

$$Var \hat{y}_0 = Var(x_0'(\beta - \hat{\beta}) + e_0) = \sigma^2(1 + x_0'(X'X)^{-1}x_0)$$

- Por tanto se tienen distintos intervalos de confianza:

$$I_{(1-\alpha)\%}(E(y_0)) = (x_0'\hat{\beta} - t_{\alpha/2;n-k}\hat{\sigma}\sqrt{x_0'(X'X)^{-1}x_0}, x_0'\hat{\beta} + t_{\alpha/2;n-k}\hat{\sigma}\sqrt{x_0'(X'X)^{-1}x_0})$$

$$I_{(1-\alpha)\%}(y_0) = (x_0'\hat{\beta} - t_{\alpha/2;n-k}\hat{\sigma}\sqrt{1 + x_0'(X'X)^{-1}x_0}, x_0'\hat{\beta} + t_{\alpha/2;n-k}\hat{\sigma}\sqrt{1 + x_0'(X'X)^{-1}x_0})$$

- Y los estadísticos, para contrastes individuales, respectivamente:

$$\frac{E(y / x_0) - x_0'\hat{\beta}}{\hat{\sigma}\sqrt{x_0'(X'X)^{-1}x_0}} \approx t_{n-k}$$

$$\frac{y_0 - x_0'\hat{\beta}}{\hat{\sigma}\sqrt{1 + x_0'(X'X)^{-1}x_0}} \approx t_{n-k}$$



III. MODELO DE REGRESIÓN LINEAL GENERAL

12. Evaluación y validación de modelos

12.1. Criterios para seleccionar un modelo entre distintas especificaciones alternativas, de varias variables exógenas potenciales o de varias formas funcionales posibles

- ✚ Coherencia del modelo estimado con los datos
 - ✓ significación conjunta del modelo (coeficientes R^2 o F y estadístico F) y
 - ✓ significación de los parámetros individuales (t -ratios)
 - ✓ adecuación a la teoría económica subyacente (signos y magnitudes de los coeficientes, propiedades de largo y corto plazo, etc.)
- ✚ Coherencia *a posteriori* con las hipótesis iniciales:
 - ✓ ausencia de correlación, homoscedasticidad, normalidad, exogeneidad de los regresores (ausencia de correlación de las variables explicativas con el término de perturbación), constancia de los parámetros, forma funcional, etc
- ✚ Principio de Parsimonia
 - ✓ los modelos elegidos deben ser parsimoniosos (no contener un excesivo número de parámetros) y a ser posible ‘anidar’ a todos los posibles modelos competidores

III. MODELO DE REGRESIÓN LINEAL GENERAL

12. Evaluación y validación de modelos (Cont.)

12.2. Medidas de precisión de las predicciones y de bondad del ajuste

Basadas en la comparación entre los valores observados y los ajustados

✚ Varianza residual: $\hat{\sigma}^2 = \frac{1}{n-k} \sum (y_i - \hat{y}_i)^2$

✚ Error absoluto medio $EAM = \frac{1}{n} \sum |y_i - \hat{y}_i|$

✚ Porcentaje medio de error $PME = \frac{1}{n} \sum |\hat{e}_i / y_i| \times 100$

✚ Raíz cuadrada del error cuadrático medio $RECM = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n}}$

✚ Error cuadrático medio $ECM = RECM^2$.

✚ El coeficiente de desigualdad de Theil

$0 \leq U \leq 1$, donde $U = 0$ indicaría un ajuste perfecto.

Para todas las medidas son deseables los valores menores

$$U = \frac{\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}}{\sqrt{\frac{1}{n} \sum y_i^2} + \sqrt{\frac{1}{n} \sum \hat{y}_i^2}}$$

12.3. Medidas de ajuste basadas en criterios de información

Basados en el valor del logaritmo de la función de verosimilitud en el modelo estimado

$$l = -\frac{n}{2} \left(1 + \log(2\pi) + \log(\hat{e}'\hat{e}/n) \right)$$

✚ Criterio de información de Akaike (1970,1974):

$$AIC = \frac{-2l + 2k}{n}$$

✚ Criterio Bayesiano de Schwarz (1978):

$$SBC = \frac{-2l + k \log(n)}{n}$$

✚ Criterio de Hannan-Quinn (1979):

$$HQC = \frac{-2l + 2k \log(\log(n))}{n}$$

Para todas las medidas *son deseables los valores menores*